

# 2017「应用微观计量经济学」暑期学校

## 政策评估与处理效应

司继春

上海对外经贸大学

2017年8月

# Rubin因果模型

思想来源：实验

1. Neyman (1923) 提出了潜在结果 (potential outcomes)
2. Fisher (1925): 推断

Rubin (1974): 在观察数据 (observational study) 中使用潜在因果的语言。

# Rubin因果模型

- ▶ 对于同一个个体，不同的处理水平对应着不同的潜在结果 (potential outcomes)
- ▶ 研究者只能观察到对应于实际接收的处理水平的结果。

例如，对于  $i = 1, \dots, N$  个个体选择是否参与一个培训项目，有两种处理水平：

1. 参与项目，记  $W_i = 1$
2. 不参与项目，记  $W_i = 0$

相应的，潜在结果  $Y_i(W_i)$  为：

1.  $Y_i(0)$ ：如果不参与的结果（如工资水平）
2.  $Y_i(1)$ ：如果参与的结果

# Rubin 因果模型

由于个体 $i$ 只能选择参与或者不参与，因而只能观察到 $Y_i(0)$ 和 $Y_i(1)$ 其中的一个。记观察到的结果为 $Y_i$ ，那么：

$$\begin{aligned} Y_i &= W_i Y_i(1) + (1 - W_i) Y_i(0) \\ &= \begin{cases} Y_i(0) & W_i = 0 \\ Y_i(1) & W_i = 1 \end{cases} \end{aligned}$$

模型设定优点：

1. 允许异质性（相比较于一般计量模型中的结构方程）
2. 在设定分配机制（assignment mechanism）之前即定义了因果（在潜在结果方程中没有内生性等）
3. 将潜在结果的建模与分配机制建模分开

因而分析分配机制非常重要！！！！

# Rubin因果模型

分配机制：

## 1. 随机实验：

1.1 处理的分配概率不随着潜在结果而改变

1.2 处理的分配概率为协变量（covariates）的已知函数

## 2. 无混淆分配（unconfounded assignment）

- ▶ 要求给定协变量，潜在结果与分配独立：

$$W_i \perp\!\!\!\perp (Y_i(0), Y_i(1)) | X_i$$

- ▶ 与随机实验差别： $P(W_i | X_i)$ 为未知函数

- ▶ 又称为：

- ▶ selection-on-observable
- ▶ exogeneity
- ▶ conditional independence assumption (CIA)

## ▶ 其他

- ▶ selection-on-unobservable
- ▶ 例：Roy Model:  $W_i = 1(Y_i(1) \geq Y_i(0))$

# Rubin因果模型

关键假设：SUTVA (Stable Unit Treatment Value Assumption) :

任何个体的潜在结果不会随着其他个体的分配而改变，  
且对于每个个体，没有其他不同形式的、可以导致不同潜在结果的处理水平。

含义：排除了：

1. 一般均衡效应 (general equilibrium effects)
2. 伙伴效应 (peer effects)
3. ...

如果违背：

1. 重新定义研究个体
2. 直接设定个体之间的交互

# Rubin 因果模型

不同形式的处理效应：

- ▶ 个体处理效应：对于个体 $i$ ，个体处理效应为 $\Delta_i = Y_i(1) - Y_i(0)$

异质性 (heterogeneous effects) :  $\Delta_i$ 随着 $i$ 的变化而变化。

- ▶ 同质处理效应 (Homogeneous treatment effects) :  $Y_i(1) - Y_i(0) = \Delta$ 
  - ▶ 例:  $Y_i = g(X_i) + \alpha W_i + u_i$
- ▶ 条件同质处理效应:  $\Delta_i = \Delta(X_i)$ 
  - ▶ 例:  $Y_i = g(X_i, D_i) + u_i \Rightarrow \Delta_i = g(X_i, 1) - g(X_i, 0) = \Delta(X_i)$
  - ▶ 例:  $Y_i = X_i' \beta + W_i X_i' \alpha + u_i$
- ▶ 异质处理效应
  - ▶  $Y_i = g(X_i, D_i, u_i)$

# Rubin 因果模型

感兴趣的处理效应:

1. 平均处理效应 (Average Treatment Effects, ATE) :  $ATE = \mathbb{E}(\Delta_i)$
2. 处理组平均处理效应 (Average Treatment Effects on the Treated, TT) :  $ATT = \mathbb{E}(\Delta_i | W_i = 1)$
3. 未处理组平均处理效应 (Average Treatment Effects on the Untreated, TUT) :  $ATUT = \mathbb{E}(\Delta_i | W_i = 0)$



# Rubin 因果模型

以上定义的是总体处理效应，然而给定样本，我们通常关注给定协变量 $X_i$ 时的处理效应：

1.  $CATE(X_i) = \frac{1}{N} \sum_{i=1}^N \mathbb{E}(\Delta_i | X_i)$
2.  $CATT(X_i) = \frac{1}{N} \sum_{i|W_i=1} \mathbb{E}(\Delta_i | X_i)$
3.  $CATUT(X_i) = \frac{1}{N} \sum_{i|W_i=0} \mathbb{E}(\Delta_i | X_i)$

# Rubin因果模型

几种处理效应关系：

- ▶ 同质处理效应：

$$ATE = ATT = ATUT = CATE(X_i) = CATT(X_i) = CATUT(X_i)$$

- ▶ 条件同质处理效应：

- ▶  $CATE(X_i) = CATT(X_i) = CATUT(X_i)$
- ▶ 可能  $ATE \neq ATT \neq ATUT$ ，由于  $X_i$  的分布随  $W_i$  不同

- ▶ 异质性处理效应：

- ▶ 如果  $Y_i(1) - Y_i(0) \parallel W_i | X_i$ ：结论同条件同质处理效应
- ▶ 否则  $CATE(X_i) \neq CATT(X_i) \neq CATUT(X_i)$

# Rubin 因果模型

其他感兴趣的处理效应:

- ▶ 分位数处理效应 (quantile treatment effects) :

$$\tau_q = F_{Y(1)}^{-1}(q) - F_{Y(0)}^{-1}(q)$$

- ▶ 处理效应的分位数:

$$\tilde{\tau}_q = F_{Y(1)-Y(0)}^{-1}(q)$$

- ▶ 最难的参数:  $(Y_i(1), Y_i(0))$  的联合分布:

$$P(Y_i(1) \leq y_1, Y_i(0) \leq y_0)$$

# Rubin 因果模型

可能的偏误：由于  $Y = WY(1) + (1 - W)Y(0) = Y(0) + W(Y(1) - Y(0))$ ，从而：

$$\begin{aligned} \mathbb{E}(Y|W=1) - \mathbb{E}(Y|W=0) = \\ (\text{ATT}) \quad \mathbb{E}(Y_1 - Y_0|W=1) + \\ (\text{Selection bias}) \quad \mathbb{E}(Y_0|W=1) - \mathbb{E}(Y_0|W=0) \end{aligned}$$

如果我们关心平均处理效应：

$$\begin{aligned} \mathbb{E}(Y|W=1) - \mathbb{E}(Y|W=0) = \\ (\text{ATE}) \quad \mathbb{E}(Y_1 - Y_0) + \\ (\text{Sorting Gain}) \quad \mathbb{E}(Y_1 - Y_0|W=1) - \mathbb{E}(Y_1 - Y_0) + \\ (\text{Selection bias}) \quad \mathbb{E}(Y_0|W=1) - \mathbb{E}(Y_0|W=0) \end{aligned}$$

# 偏识别

在最宽松的假设条件下，我们可以放弃点识别（point identification），转而使用偏识别（Partial identification）

- ▶ 点识别识别具体的点
- ▶ 偏识别仅仅能够给出上下界

# 偏识别

如果潜在因果 $Y_i(W_i)$ 是有界的, 比如,  $Y_i(W_i) = 0/1$ , 由于:

$$\begin{aligned}\mathbb{E}(Y_i(1) - Y_i(0)) &= \mathbb{E}(Y_i(1) | W_i = 1) P(W_i = 1) \\ &\quad + \mathbb{E}(Y_i(1) | W_i = 0) P(W_i = 0) \\ &\quad - \mathbb{E}(Y_i(0) | W_i = 1) P(W_i = 1) \\ &\quad - \mathbb{E}(Y_i(0) | W_i = 0) P(W_i = 0)\end{aligned}$$

因而其下界为:

$$\begin{aligned}\tau_l &= \mathbb{E}(Y_i(1) | W_i = 1) P(W_i = 1) \\ &\quad - P(W_i = 1) - \mathbb{E}(Y_i(0) | W_i = 0) P(W_i = 0)\end{aligned}$$

上界为:

$$\begin{aligned}\tau_u &= \mathbb{E}(Y_i(1) | W_i = 1) P(W_i = 1) \\ &\quad + P(W_i = 0) - \mathbb{E}(Y_i(0) | W_i = 0) P(W_i = 0)\end{aligned}$$

# 偏识别

如果我们关心潜在结果的分布，由于：

$$\begin{aligned} F_{Y_1}(y) &= P(Y_i(1) \leq y) \\ &= P(Y_i(1) \leq y | W_i = 1) P(W_i = 1) \\ &\quad + P(Y_i(1) \leq y | W_i = 0) P(W_i = 0) \end{aligned}$$

因而： $F_{Y_1}(y)$ 的下界为：

$$P(Y_i(1) \leq y | W_i = 1) P(W_i = 1)$$

而上界为：

$$P(Y_i(1) \leq y | W_i = 1) P(W_i = 1) + P(W_i = 0)$$

# 偏识别

其他如：

1. Manski and Pepper(2000)
2. Jun, Lee and Shin (2016)



# Matching

在Unconfoundedness假设条件下，可以方便的得到处理效应的识别。关键假设：

1. Unconfoundedness假设（CIA假设）：

$$W_i \perp\!\!\!\perp (Y_i(1), Y_i(0)) | X$$

2. 共同支撑假设（Common support assumption, CSA）：

$$0 < P(W_i = 1 | X_i) < 1$$

# Matching

CIA意味着均值独立，即：

$$\mathbb{E}(Y_i(1) | X_i, W_i) = \mathbb{E}(Y_i(1) | X_i)$$

$$\mathbb{E}(Y_i(0) | X_i, W_i) = \mathbb{E}(Y_i(0) | X_i)$$

而CSA需要对于相同的 $X_i$ ，都有处理组和非处理组：经常需要trimming。

# Matching

由于:

$$\begin{aligned}\mathbb{E}(Y_i | W_i = 1, X_i) - \mathbb{E}(Y_i | W_i = 0, X_i) \\&= \mathbb{E}(Y_i(1) | X_i, W_i = 1) - \mathbb{E}(Y_i(0) | X_i, W_i = 0) \\&= \mathbb{E}(Y_i(1) | X_i) - \mathbb{E}(Y_i(0) | X_i) \\&= \mathbb{E}(Y_i(1) - Y_i(0) | X_i)\end{aligned}$$

因而

$$\mathbb{E}[\mathbb{E}(Y_i | W_i = 1, X_i) - \mathbb{E}(Y_i | W_i = 0, X_i)] = \mathbb{E}(Y_i(1) - Y_i(0))$$

同理:

$$\begin{aligned}\mathbb{E}[\mathbb{E}(Y_i | W_i = 1, X_i) - \mathbb{E}(Y_i | W_i = 0, X_i) | W_i = 1] = \\ \mathbb{E}(Y_i(1) - Y_i(0) | W_i = 1)\end{aligned}$$

# Matching

方法一：回归

设定

$$\mathbb{E}(Y_i | W_i = 1, X_i) = \mathbb{E}(Y_i(1) | X_i) = \mu_1(X_i)$$

$$\mathbb{E}(Y_i | W_i = 0, X_i) = \mathbb{E}(Y_i(0) | X_i) = \mu_0(X_i)$$

平均处理效应：

$$\hat{\tau}_{\text{reg}} = \frac{1}{N} \sum_{i=1}^N [\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i)]$$

1. 简单线性回归：

$$Y_i = \alpha + X_i' \beta + \tau \cdot W_i + \epsilon_i$$

或者：

$$Y_i = \alpha + X_i' \beta + \tau \cdot W_i + W_i (X_i - \bar{X})' \delta + \epsilon_i$$

2. 非参数回归

# Matching

或者：Nearest Neighbor Matching:

1. 给定一个正的常数 $M$ ，比如 $M = 1$
2. 令 $d(\cdot, \cdot)$ 为一个距离函数，比如欧几里得距离：

$$d(X_i, X_j) = (X_i - X_j)' (X_i - X_j)$$

或者Mahalanobis距离：

$$d(X_i, X_j) = (X_i - X_j)' \Sigma_X^{-1} (X_i - X_j)$$

# Matching

Nearest-neighbor matching: 对于任意处理组的 $i$ ，从控制组中找到最近的 $M$ 个控制组个体，记：

$$J_M(i) = \{l_1(i), \dots, l_M(i)\}$$

定义

$$\hat{Y}_i(0) = \frac{1}{M} \sum_{m \in J_M(i)} Y_m$$

可以使用：

$$\frac{1}{N_1} \sum_{i|W_i=1} [Y_i(1) - \hat{Y}_i(0)]$$

# Matching

实践中，有不同的匹配方案：

1. 选择M，一般而言如果控制组数量远远大于实验组数量，可以使用较多的M
2. 序贯/非序贯
3. 贪婪/非贪婪
4. 放回/无放回
5. 先进行分组，组内进行匹配
6. 使用propensity score进行排序，进而匹配

# Matching

倾向得分匹配的步骤:

1. 定义距离
2. 匹配
3. 评估匹配结果:
  - 3.1 balancing: t-test、Standardised Bias
  - 3.2 unconfoundedness: 使用明显无效应的其他的Y
4. 评估政策效应
5. 敏感性分析



# Matching

其他匹配方法：

1. Kernel matching
2. Radius matching
3. Stratification or interval matching
4. Propensity score matching

# Matching

倾向得分 (Propensity score) 方法: Rosenbaum and Rubin(1983)  
证明:

$$W_i \perp\!\!\!\perp (Y_i(1), Y_i(0)) \mid X_i \iff W_i \perp\!\!\!\perp (Y_i(1), Y_i(0)) \mid P(X_i)$$

因而控制倾向得分匹配就足够了。

# Matching

Rosenbaum and Rubin(1983)提出了三阶段的方法：

1. 估计倾向得分：

$$P(W_i|X_i)$$

2. 用 $Y_i$ 对 $W_i$ 和 $P_i$ 做回归，得到 $\hat{E}(Y_i|W_i, P(X_i))$

3. 估计ATT：

$$\frac{1}{N_1} \sum_{i|W_i=1} [Y_i(1) - \hat{Y}_i(0)]$$

注意在使用Propensity Score时，一定要注意Common support假设：trimming！

# Matching

其他方法：

1. blocking/subclassification/stratification
2. nearest-neighbor matching
3. kernel matching
4. ...

## Matching

注意到，由于：

$$\begin{aligned}\mathbb{E} \left( \frac{W_i Y_i}{P(X_i)} \right) &= \mathbb{E} \left( \frac{W_i Y_i(1)}{P(X_i)} \right) \\ &= \mathbb{E} \left[ \mathbb{E} \left( \frac{W_i Y_i(1)}{P(X_i)} \middle| X_i \right) \right] \\ &= \mathbb{E} \left[ \frac{\mathbb{E}(W_i Y_i(1) | X_i)}{P(X_i)} \right] \\ &= \mathbb{E} \left[ \frac{\mathbb{E}(W_i | X_i) \mathbb{E}(Y_i(1) | X_i)}{P(X_i)} \right] \\ &= \mathbb{E} [\mathbb{E}(Y_i(1) | X_i)] = \mathbb{E}(Y_i(1))\end{aligned}$$

同理：

$$\mathbb{E} \left( \frac{(1 - W_i) Y_i}{1 - P(X_i)} \right) = \mathbb{E}(Y_i(0))$$

# Matching

因而平均处理效应：

$$\tau_{\text{ATE}} = \mathbb{E} \left[ \frac{W_i Y_i}{P(X_i)} - \frac{(1 - W_i) Y_i}{1 - P(X_i)} \right]$$

可以使用：

$$\hat{\tau}_{\text{ATE}} = \frac{1}{N} \sum_{i=1}^N \left[ \frac{W_i Y_i}{P(X_i)} - \frac{(1 - W_i) Y_i}{1 - P(X_i)} \right]$$

进行估计，称为Inverse Propensity Weighting(IPW)。其中 $P(X_i)$ 可以使用Logistic sieve估计量（Hirano, Imbens and Ridder, 2003）。

# Matching

然而IPW方法对倾向得分非常敏感。可以考虑使用Robins等人提出的双向稳健（Double robustness）方法：

1. 结合了回归方法和IPW
2. 只需要 $P(X_i)$ 或者结果方程至少有一个设定正确（双向稳健）

最小化：

$$\min_{\alpha_0, \beta_0} \sum_{i|W_i=0} \frac{[Y_i - \alpha_0 - \beta'_0 (X_i - \bar{X}_i)]}{P(X_i; \hat{\gamma})}$$
$$\min_{\alpha_1, \beta_1} \sum_{i|W_i=1} \frac{[Y_i - \alpha_1 - \beta'_1 (X_i - \bar{X}_i)]}{1 - P(X_i; \hat{\gamma})}$$

平均处理效应为：

$$\hat{\tau}_{ATE} = \hat{\alpha}_1 - \hat{\alpha}_0$$

# Matching

其他方法：Imai and Ratkovic (2014): 解:

$$\frac{1}{N} \sum_{i=1}^N g_{\gamma}(W_i, X_i) = \frac{1}{N} \sum_{i=1}^N \left[ \left( \frac{W_i}{P(X_i; \gamma)} - \frac{1 - W_i}{1 - P(X_i; \gamma)} \right) f(X_i) \right] = 0$$

仍然是双向稳健的。此外，Fan et al. (2016)做了推广。




违背Unconfoundedness假设，但是有面板数据的条件下：双重差分模型（Difference-in-differences）。

一般设定：

1. 分组变量：  $G_{ig} = 1$ ：处理组；  $G_{ig} = 0$ ：实验组
2. 时间变量：  $d_t = 0/1$
3. 处理  $W_{it} = d_t \cdot G_i$
4. Outcome：  $Y_{igt}$

	$G_{ig} = 0$	$G_{ig} = 1$
$d_t = 0$	0	0
$d_t = 1$	0	1

关键假设：共同趋势 (Common trend)



双重差分模型：

1. 第一次差分：对于两个不同的分组，分别计算：

$$\Delta_1 = \mathbb{E}(Y_{igt} | G_{gi} = 1, d_t = 1) - \mathbb{E}(Y_{igt} | G_{gi} = 1, d_t = 0)$$

$$\Delta_0 = \mathbb{E}(Y_{igt} | G_{gi} = 0, d_t = 1) - \mathbb{E}(Y_{igt} | G_{gi} = 0, d_t = 0)$$

2. 第二次差分：处理效应：

$$\tau = \Delta_1 - \Delta_0$$

实践中，等价于使用回归：

$$Y_{igt} = c + \lambda \cdot d_t + \gamma \cdot G_{ig} + \beta \cdot d_t \cdot G_{ig} + u_{it}$$

即第一次差分：

$$\Delta_1 = \mathbb{E}(Y_{igt} | G_{gi} = 1, d_t = 1) - \mathbb{E}(Y_{igt} | G_{gi} = 1, d_t = 0) = \lambda + \beta$$

$$\Delta_0 = \mathbb{E}(Y_{igt} | G_{gi} = 0, d_t = 1) - \mathbb{E}(Y_{igt} | G_{gi} = 0, d_t = 0) = \lambda$$

第二次差分：

$$\tau = \Delta_1 - \Delta_0 = \beta$$

实践中的设定：

1. 加入控制，即可以假定给定控制 $x_{it}$ 的情况下，共同趋势假设成立，使用回归：

$$Y_{igt} = c + \lambda \cdot d_t + \gamma \cdot G_{ig} + \beta \cdot d_t \cdot G_{ig} + x'_{it}\beta + u_{it}$$

2. 直接控制个体和时间效应，而不是分组变量：

$$Y_{igt} = c_i + \lambda_t + \beta \cdot d_t \cdot G_{ig} + x'_{it}\beta + u_{it}$$

3. 直接加入个体趋势：

$$Y_{igt} = c_i + \lambda_t + \gamma_{1i}t + \gamma_{2i}t^2 + \beta \cdot d_t \cdot G_{ig} + x'_{it}\beta + u_{it}$$

4. 交互固定效应 (Bai, 2009)

$$Y_{igt} = c'_i\lambda_t + \beta \cdot d_t \cdot G_{ig} + x'_{it}\beta + u_{it}$$

其他设定问题:

1. 多期DID: 将 $d_t \cdot G_{ig}$ 替换为 $d_{it}$ , 其中 $d_{it}$ 指第 $t$ 期第 $i$ 个个体是否接受处理。
2. 标准误的问题: (广义的) 自相关严重影响推断, cluster是必须的

检验：

1. Placebo test：提前冲击发生的时间
2. 设定：

$$Y_{igt} = c_i + \lambda_t + \sum_{\tau=1}^T \beta_{\tau} \cdot 1\{t = \tau\} \cdot G_{ig} + x'_{it}\beta + u_{it}$$

2.1 冲击发生之前不显著

2.2 冲击发生之后显著

其他方法：

1. Triple differences: e.g., 某个地区 $g$ 的某个特定组别 $r$ 收到处理：加入两两交互项，三个变量的交互项的系数为处理效应。
2. DID+Matching
3. 非线性DID：Changes-in-Changes



非线性DID: CIC (Athey and Imbens, 2006)

假设:

1.  $Y_i(0) = h(U_i, T_i)$ , 其中 $h(\cdot, \cdot)$ 对 $U_i$ 为单调的函数,  $T_i$ 为时间
2.  $U \perp\!\!\!\perp T | G$ , 即给定分组,  $U$ 的分布与时间独立
3. support假设

关键结论:

$$F_{Y^N, 11}(y) = F_{Y, 10} \left( F_{Y, 00}^{-1} (F_{Y, 01}(y)) \right)$$

其中 $F_{Y, gt}$ 为分布函数。进而处理效应:

$$\tau_{CIC} = \mathbb{E}(Y_{11}) - \mathbb{E} \left( F_{01}^{-1} (F_{00}(Y_{10})) \right)$$

断点回归 (Regression discontinuity) 用于政策变量仅仅取决于一个连续变量 $x$ , 且在某个点 $x = c$ 处, 参与概率有跳跃的情况。

## 1. Sharp RD:

$$W_i = 1 (X_i \geq c)$$

## 2. Fuzzy RD

$$\lim_{x \downarrow c} P(W_i | X_i = c) \neq \lim_{x \uparrow c} P(W_i | X_i = c)$$

- ▶ 优点: 识别干净
- ▶ 缺点: 外部有效性




Fig. 1. Assignment probabilities (SRD).




Fig. 2. Potential and observed outcome regression functions.




Fig. 3. Assignment probabilities (FRD).




Fig. 4. Potential and observed outcome regression (FRD).

# Sharp RD

政策效应:

$$\tau_{\text{SRD}} = \lim_{x \downarrow c} \mathbb{E}(Y_i | X_i = c) - \lim_{x \uparrow c} \mathbb{E}(Y_i | X_i = c)$$

估计:

1. 参数方法

2. 非参数方法:

2.1 在 $X = c$ 两边取两个小邻域计算均值

2.2 Local constant

2.3 Local polynomial (Local linear): 使用多项式在 $X = c$ 两边  
(( $c - h, c + h$ )) 对outcome进行拟合:

$$Y_i = \alpha + \tau W_i + 1 \{X_i \geq c\} f_r(X_i - c) + 1 \{X_i < c\} f_l(X_i - c) + u_i$$

# Fuzzy RD

$$\text{令 } S_i = 1 \{X_i \geq c\}$$

- ▶ Intention-to-treat (ITT):

$$Y_i = \alpha_1 + \tau_{ITT} S_i + S_i \cdot f_r(X_i - c) + [1 - S_i] f_l(X_i - c) + u_i$$

- ▶ 政策概率:

$$W_i = \alpha_2 + \delta \cdot S_i + S_i \cdot g_r(X_i - c) + [1 - S_i] g_l(X_i - c) + v_i$$

- ▶ 结构方程:

$$Y_i = \alpha + \tau \cdot W_i + S_i \cdot h_r(X_i - c) + [1 - S_i] h_l(X_i - c) + \epsilon_i$$

# Fuzzy RD

估计:

1. 根据以上可知:

$$\tau = \frac{\tau_{\text{ITT}}}{\delta}$$

其中 $\tau_{\text{ITT}}$ 和 $\delta$ 都可以通过Local polynomial估计得到

2. 2SLS

问题:

1. 窗宽选取?
2. 多项式阶数

一般步骤:

1. 画图
2. 检验manipulation
3. 推断
4. 稳健性检验



## 检验manipulation: McCrary(2008)

